

Diseño e Implementación de Agentes

Inteligentes basados en LLMs

Grupo 7

Valentina Ducasse - ducassevalentina@gmail.com
Wenceslao Echevarría - wenceseechevarria@hotmail.com
Nicolás García - nicoag.2000@gmail.com
Joaquín Sola - joaquin_sola@hotmail.com
Nicolás Springer - nicosspringer16@gmail.com

Descripción general del problema

Las personas con discapacidad visual cuentan con herramientas de movilidad y asistencia, como el bastón blanco o los perros guía, que les permiten desenvolverse físicamente en su entorno y detectar obstáculos inmediatos. Sin embargo, estas herramientas no proporcionan asistencia para tareas cotidianas y administrativas que requieren la interpretación semántica de información visual específica, lo que supone una barrera significativa para su independencia y privacidad.

Un obstáculo crítico para la autonomía de estas personas es la gestión y el pago de servicios. Actualmente, dependen en gran medida de la asistencia de terceros para leer los montos, entidades cobradoras y fechas de vencimiento, enfrentándose a este problema en dos frentes simultáneos: el físico (facturas impresas en papel) y el digital (facturas recibidas por correo electrónico en formato PDF o imágenes digitales). A esto se suma el desafío de identificar, discriminar y organizar correctamente la denominación de los billetes de curso legal que tienen a disposición para efectuar dichos pagos de manera presencial.

El problema radica en la falta de un sistema tecnológico accesible e integrado que traduzca esta información multimodal (documentos impresos, documentos digitales y papel moneda) en indicaciones auditivas claras, estructuradas y precisas. La ausencia de una herramienta de estas características impide que el usuario pueda tener un control real sobre el contexto de la transacción, imposibilitando la resolución de sus obligaciones económicas de forma completamente autónoma y segura.

Definición del objetivo del agente

El objetivo principal del agente inteligente es asistir a personas con discapacidad visual en la gestión y resolución de pagos de servicios, procesando tanto comprobantes en papel como documentos digitales, y facilitando el manejo autónomo de dinero en efectivo. El sistema está diseñado como un soporte cognitivo y accesible que automatiza la interpretación semántica del entorno financiero inmediato del usuario mediante un esquema de interacción transaccional a demanda.

Para lograr esto, el agente procesará capturas fotográficas de facturas impresas, archivos digitales (en formatos PDF o imágenes) y capturas de billetes físicos de curso legal dispuestos sobre una superficie. El propósito fundamental del agente es triple:

1. Extraer de manera estructurada los datos críticos de la factura (entidad emisora, monto total y fecha de vencimiento).
2. Cuantificar e identificar el valor nominal del dinero en efectivo disponible para el pago.
3. Calcular, a través de una lógica algorítmica interna, la combinación óptima de billetes que el usuario debe entregar para saldar la deuda, especificando además el vuelto que debe recibir.

El agente operará de forma interactiva guiando al usuario paso a paso y utilizando interfaces de voz (*Speech-to-Text* y *Text-to-Speech*) como canal principal de comunicación para garantizar una accesibilidad estricta. Cabe destacar que el sistema funcionará exclusivamente como una herramienta de asistencia informativa, de validación visual y de cálculo aritmético, sin intervenir de manera directa en transacciones bancarias electrónicas ni sustituir la toma de decisiones final del usuario.

Identificación de percepciones y acciones (Tools)

En esta sección se definen las entradas que el agente es capaz de procesar y las herramientas específicas (Tools) que puede invocar para interactuar con la información y resolver la tarea encomendada.

Percepciones (Entradas del entorno):

- **Transcripciones de voz del usuario:** Comandos, consultas e intenciones capturadas mediante el micrófono del dispositivo y procesadas por un módulo *Speech-to-Text* (STT).
- **Mensajes de texto:** Entrada alternativa o de respaldo generada a través de la interfaz web.
- **Fotografías del entorno físico:** Imágenes capturadas por la cámara del celular a demanda del usuario, que contienen facturas de servicios en papel o billetes físicos dispuestos sobre una superficie.
- **Documentos digitales:** Archivos en formato PDF o imágenes (capturas de pantalla) correspondientes a facturas electrónicas proporcionadas por el usuario.
- **Historial conversacional:** Contexto a corto plazo mantenido en memoria durante la sesión para asegurar la coherencia en interacciones de múltiples pasos.

Acciones / Tools:

- **extraer_datos_factura(documento):** Utiliza las capacidades multimodales del modelo para analizar la imagen de una factura física o un archivo PDF. Su objetivo excluyente es extraer la información clave y retornar una estructura de datos estandarizada que contenga: entidad_cobradora, monto_total y fecha_vencimiento.
- **identificar_billetes(imagen_dinero):** Analiza una fotografía que contiene dinero en efectivo. Su función es identificar los billetes de curso legal (Pesos Argentinos) presentes en la imagen y retornar un arreglo estructurado que detalle la denominación de cada billete y su posicion_espacial aproximada (ej. izquierda, centro, derecha) para orientar al usuario en la manipulación física del dinero.

- **calcular_cambio_y_pago(datos_factura, lista_billetes):** Herramienta de ejecución determinística implementada íntegramente en código Python. No utiliza inferencia de LLM para evitar alucinaciones aritméticas. Recibe los JSONs generados por las dos herramientas anteriores y se encarga de: sumar el dinero total disponible, verificar si es suficiente para cubrir el monto_total, determinar la combinación óptima de billetes a entregar y calcular el vuelto exacto que el usuario debe recibir.

Especificar el ambiente en donde el agente se desenvuelve

El entorno en el cual el agente opera se divide en dimensiones claramente delimitadas: el espacio físico donde el usuario interactúa con los elementos, y la infraestructura digital donde ocurre el procesamiento multimodal y la orquestación. Debido al ajuste del alcance hacia un enfoque transaccional, el ambiente difiere significativamente del planteo original de navegación continua.

Ambiente Físico: A diferencia de los sistemas de asistencia para movilidad, este agente opera en un entorno físico de naturaleza controlada y cuasi-estática. Típicamente, consiste en una superficie plana (como una mesa en el domicilio del usuario, un escritorio o el mostrador de un comercio) donde se disponen los elementos a analizar: facturas impresas y billetes de papel. Las principales variables ambientales que el agente debe ser capaz de tolerar y procesar incluyen:

- **Condiciones lumínicas:** Variaciones entre luz natural y artificial, reflejos sobre el papel, y sombras proyectadas por las manos del usuario o el propio dispositivo móvil.
- **Encuadre y perspectiva:** Diferentes ángulos de captura fotográfica, posibles recortes parciales de los documentos o superposición leve de los billetes sobre la superficie.

Ambiente Digital (Interfaz de Usuario): El entorno digital primario es el dispositivo móvil (teléfono inteligente) del usuario. El agente se presenta a través de una aplicación web interactiva desde el navegador del celular. Este entorno actúa como puente de recolección de flujos de entrada (activación de cámara para fotografías, carga de archivos PDF y captura de audio por micrófono). A su vez, es el entorno de salida, reproduciendo las instrucciones y resultados del agente de forma estrictamente compatible con herramientas de accesibilidad, utilizando síntesis de voz (Text-to-Speech) y contraste visual alto para restos visuales.

Definición de la arquitectura del agente

El sistema se estructura bajo una arquitectura modular orientada a servicios, separando claramente la capa de presentación (interfaz accesible), la lógica de orquestación (el agente) y el procesamiento cognitivo (modelo fundacional). El diseño se basa en un grafo de estados que permite un flujo de control predecible y cíclico.

Los componentes principales de la arquitectura son los siguientes:

- **Orquestador del Agente/Planificación Multi-step (LangGraph):** Actúa como el cerebro del flujo de control. Define un grafo de estados donde cada nodo representa una etapa del proceso (recepción de input, análisis de documento, análisis de dinero, validación y cálculo). LangGraph permite que el agente evalúe el estado actual de la transacción y decida, de forma autónoma, qué herramienta invocar a continuación o si es necesario solicitar una aclaración al usuario.

- **Modelo Central (LLM Multimodal):** Se utiliza **Gemini 1.5 Flash** a través de su API. Este modelo actúa como el motor de percepción y razonamiento del agente. Es el encargado de procesar tanto el lenguaje natural del usuario como las entradas multimodales (imágenes físicas y archivos digitales), abstrayendo la información visual hacia formatos estructurados (JSON) mediante un *System Prompt* con restricciones estrictas de salida.
- **Backend y Lógica Determinística (FastAPI):** Desarrollado en Python, este servidor expone los *endpoints* necesarios para la comunicación con la interfaz móvil. Más allá de alojar a LangGraph, el backend contiene el entorno de ejecución de las herramientas matemáticas (calcular_cambio_y_pago). Al procesar las operaciones aritméticas en código duro de Python, se blindo al sistema contra las alucinaciones matemáticas inherentes a los LLMs.
- **Módulo de Memoria de Corto Plazo:** Se implementa una memoria conversacional en la ventana de contexto (*context window*) limitada a la duración de la transacción en curso. Esto permite al agente mantener el hilo conductor, recordando, por ejemplo, el monto de una factura previamente analizada mientras espera que el usuario capture la fotografía del dinero.
- **Interfaz de Usuario y Capa de Accesibilidad (Frontend):** Una aplicación web interactiva que funciona como punto de contacto en el dispositivo móvil del usuario. Integra módulos de *Speech-to-Text* (ej. Whisper API) para capturar las intenciones por voz, y *Text-to-Speech* (ej. gTTS) para verbalizar las respuestas y los resultados de los cálculos. Esta capa es responsable de empaquetar las fotografías y documentos en cargas útiles (*payloads*) manejables para el backend.
- **Módulo de Observabilidad:** Un sistema de *logging* integrado en el backend que registra la traza de ejecución del grafo: entradas y salidas de cada nodo, latencias de la API del LLM, y las respuestas finales generadas. Esto es crucial para la evaluación del rendimiento y la depuración de errores durante las pruebas empíricas.

Definición de la estrategia de evaluación del agente

Para validar el correcto funcionamiento del sistema y garantizar la seguridad del usuario, se implementará un banco de 10 casos de prueba distribuidos en tres escenarios clave:

Categoría de Prueba	Escenario de Entrada	Comportamiento Esperado	Validación
Happy Path	Factura de la EPE nítida + 2 billetes de \$10.000 limpios.	Extracción correcta de montos, reconocimiento exacto del efectivo y cálculo del vuelto sin errores.	Determinística (Código) y LLM-as-judge.

Casos Límite / Ambiguos	Factura vencida o con dos montos distintos (ej. pago total vs. pago fuera de término).	El agente debe detectar la ambigüedad y preguntar al usuario por voz qué monto desea abonar.	Subjetiva / Evaluada por prompt de control.
Entradas Adversariales	El usuario sube la foto de una tarjeta de la carnicería o un billete de un juego de mesa.	El agente debe rechazar el elemento de forma amable indicando que no es un comprobante válido ni dinero de curso legal.	Determinística (Fallo controlado en la Tool).

Banco de Casos de Prueba para la Evaluación del Agente

Categoría 1: Escenarios Principales

Prueban el funcionamiento óptimo del sistema cuando el usuario interactúa correctamente y los datos son legibles.

Caso 1: Flujo estándar con factura física y efectivo exacto

- Entrada: Foto nítida de factura impresa de la EPE (Monto: \$34.000) + Foto de dos billetes sobre la mesa (un billete de \$20.000, uno de \$10.000 y dos de \$2000).
- Flujo del Grafo: Inicio → extraer_datos_factura → identificar_billetes → calcular_cambio_y_pago → Fin.
- Comportamiento Esperado: El agente verbaliza: *"Factura de la Empresa Provincial de la Energía detectada por un total de 34.000 pesos con vencimiento el 15 de julio. Detecté un total de 34.000 pesos en efectivo. El dinero es exacto para pagar. Entregue todos los billetes sobre la mesa. No debe recibir vuelto."*
- Validación: Determinística para los montos extraídos y el cálculo de la función calcular_cambio_y_pago ($\$34.000 - \$34.000 = \$0$).

Caso 2: Carga de documento digital (PDF) con vuelto requerido

- Entrada: Archivo PDF de factura digital de Aguas Santafesinas (Monto: \$5.350) + Foto de un billete de \$10.000.
- Flujo del Grafo: Inicio → extraer_datos_factura (procesando PDF) → identificar_billetes → calcular_cambio_y_pago → Fin.
- Comportamiento Esperado: El agente reporta el monto del PDF y el efectivo. El motor matemático calcula la diferencia y responde por voz: *"Factura de Aguas Santafesinas por 5.350 pesos. Disponés de un billete de 10.000 pesos en el centro. Debes entregar este billete. Tu vuelto debe ser de 4.650 pesos."*
- Validación: Determinística en el cálculo matemático ($\$10.000 - \$5.350 = \$4.650$).

Caso 3: Interacción asincrónica guiada por pasos (Uso de Memoria)

- Entrada: Paso 1: Audio del usuario diciendo *"Quiero pagar una factura"* y sube foto de factura de Telecom (\$8.000). Paso 2 (luego de la respuesta del agente): Foto de un billete de \$10.000.
- Flujo del Grafo:
 - Paso 1: Inicio → extraer_datos_factura → Solicitar_Efectivo (Espera en nodo).
 - Paso 2: Recepción_Efectivo → identificar_billetes → calcular_cambio_y_pago → Fin.
- Comportamiento Esperado: El agente recuerda la factura gracias a la memoria de corto plazo y al recibir la foto del dinero dice: *"Perfecto, retomamos el pago de Telecom por 8.000 pesos. Con el billete de 10.000 pesos que me mostrás, pagás la factura y te tienen que devolver 2.000 pesos."*
- Validación: Subjetiva (LLM-as-judge) para comprobar que el hilo conversacional mantiene coherencia e invoca la memoria transaccional.

Caso 4: Optimización de combinación de billetes

- Entrada: Factura de API (Monto: \$3.800) + Foto con un fajo desordenado de billetes (un billete de \$5.000, dos de \$2.000, uno de \$1.000).
- Flujo del Grafo: Inicio → extraer_datos_factura → identificar_billetes → calcular_cambio_y_pago → Fin.
- Comportamiento Esperado: La herramienta lógica analiza la combinación que minimiza el vuelto y arriesga menos dinero grande. Verbaliza: *"El total es 3.800 pesos. En la mesa tenés un billete de 2.000 a la izquierda y otro de 2.000 al centro. Entregá esos dos billetes (total 4.000 pesos). Te tienen que dar 200 pesos de vuelto. Guardá el billete de 5.000 y el de 1.000."*
- Validación: Determinística mediante algoritmo de optimización (Problema del cambio/vuelto en Python).

Categoría 2: Casos Límite o Ambiguos

Escenarios complejos que desafían las reglas lógicas del negocio o la claridad de los datos.

Caso 5: Factura con doble vencimiento o recargos por mora

- Entrada: Foto de una factura donde figuran dos montos legibles: *"Primer Vencimiento (10/06): \$6.000"* y *"Segundo Vencimiento (22/06): \$8000"*. (Fecha actual simulada: 15 de junio).
- Flujo del Grafo: Inicio → extraer_datos_factura → Evaluar_Fecha → Nodo_Aclaración → Fin.
- Comportamiento Esperado: El agente detecta que la fecha actual sobrepasó el primer vencimiento. Alerta al usuario: *"La factura de servicios posee un recargo. El primer vencimiento ya caducó. El monto a abonar actual es de 8000 pesos, correspondiente al segundo vencimiento del 22 de junio. ¿Deseas continuar con este monto?"*
- Validación: LLM-as-judge para verificar que el prompt del sistema procesa correctamente las fechas relativas y selecciona el monto punitivo correspondiente.

Caso 6: Fondos insuficientes para realizar el pago

- Entrada: Factura municipal (Monto: \$4.500) + Foto de la mesa que solo contiene un billete de \$2.000 y uno de \$1.000 (Total disponible: \$3.000).

- Flujo del Grafo: Inicio → extraer_datos_factura → identificar_billetes → calcular_cambio_y_pago → Nodo_Falta_Dinero → Fin.
- Comportamiento Esperado: La lógica de Python frena la operación transaccional y el agente emite una advertencia auditiva clara: *"El total de la factura es de 4.500 pesos, pero solo detecté 3.000 pesos sobre la mesa. Te faltan 1.500 pesos para completar el pago. Por favor, agregá más billetes a la superficie y tomá una nueva fotografía."*
- Validación: Determinística. Comprobación de la bandera booleana fondos_suficientes = False devuelta por la herramienta de cálculo.

Caso 7: Billetes superpuestos o con oclusión parcial

- Entrada: Foto donde un billete de \$10.000 tapa la mitad inferior de un billete de \$5.000, pero el número "5000" superior es visible.
- Flujo del Grafo: Inicio → identificar_billetes → Evaluar_Confianza_Vision → Fin.
- Comportamiento Esperado: El agente aplica su capacidad de visión artificial. Si el umbral de confianza del JSON es alto, prosigue indicando la posición espacial: *"Detecto un billete de 10.000 pesos al centro y, parcialmente debajo de este, un billete de 5.000 pesos. Sepáralos un poco para mayor seguridad si vas a pagar con ellos."*
- Validación: Inspección mediante la interfaz de observabilidad (FastAPI logs) del campo descriptivo del JSON emitido por Gemini.

Categoría 3: Entradas Adversariales o Fuera de Dominio

Situaciones donde se ingresan datos erróneos, malintencionados o de mala calidad, buscando que el sistema falle controladamente.

Caso 8: Captura ilegible, borrosa o con fallas críticas de iluminación

- Entrada: Foto de una factura completamente movida (con blur de cámara) o a oscuras donde el LLM no puede procesar los caracteres.
- Flujo del Grafo: Inicio → extraer_datos_factura → Manejador_Errores_Validacion → Fin.
- Comportamiento Esperado: El sistema no inventa datos (cero alucinación). Responde de forma accesible: *"No he podido leer los datos de la factura porque la imagen se encuentra borrosa o la iluminación es muy baja. Por favor, encendé la luz o mantené el celular firme y volvé a tomar la foto."*
- Validación: Determinística. La tool devuelve un código de error de lectura o campos vacíos (None), forzando al grafo al nodo de re-intento.

Caso 9: Documento fuera de dominio (No es una factura)

- Entrada: El usuario sube por error la foto del menú de una rotisería o un folleto publicitario de un supermercado local.
- Flujo del Grafo: Inicio → extraer_datos_factura → Filtro_Dominio → Fin.
- Comportamiento Esperado: El agente detecta que la estructura no corresponde a una factura líquida de servicios públicos o privados. Indica: *"El documento analizado no parece ser una factura de servicios válida. No encontré una entidad emisora ni un total a pagar regular. Asegurate de estar fotografiando un comprobante de pago."*
- Validación: LLM-as-judge. El prompt del sistema debe clasificar el tipo de documento antes de intentar parsear variables.

Caso 10: Dinero falso, extranjero o fuera de curso legal

- Entrada: Foto de la mesa que contiene billetes de dólares estadounidenses, billetes del juego "Monopoly", o un billete de \$5 pesos argentinos (fuera de curso legal).
- Flujo del Grafo: Inicio → identificar_billetes → Filtro_Moneda_Legal → Fin.
- Comportamiento Esperado: El agente ignora el papel moneda inválido para el cálculo y alerta al usuario por voz: *"Atención: El papel detectado a la izquierda no corresponde a Pesos Argentinos vigentes. Asegurate de colocar sobre la mesa únicamente billetes actuales de curso legal."*
- Validación: Determinística. El arreglo de la tool identificar_billetes debe retornar vacío o marcar los elementos con etiquetas de invalidez para que la función aritmética los compute como \$0.